

Poređenje konvolutivnih i attention zasnovanih arhitektura za klasifikaciju slika


Dragana Vasić 1105/25

Vlada Marić 1092/22

Ideja


- Projekat zasnovan na radu [1].
- Autor kombinuje komponente različitih arhitektura, kao što su Inception, Residual Networks i Attention.
- Upitno je šta bi se dobilo takvom kombinacijom.
- Naš pristup je bio da uporedimo novu „iteraciju” konvolutivnih mreža i modele zasnovane na konceptu Attention-a.
- ConvNeXt kao unapređena konvolutivna mreža.
- Vision Transformer i Swin transformer kao arhitekture zasnovana na konceptu pažnje.
- Zadržali smo isti skup podataka, pre svega zbog dostupnih računarskih resursa.

ConvNeXt arhitektura




- Zasnovana na modernoj konvolutivnoj arhitekturi, inspirisanoj nekim principima Transformer modela.
- Slika se deli na manje regione, koji se kroz slojeve postepeno smanjuju i obrađuju.
- Koristi Depthwise Convolution, gde se svaki kanal obrađuje zasebno, za efikasno izvlačenje prostornih karakteristika.
- Arhitektura je hijerarhijska, slično kao kod klasičnih konvolutivnih mreža.
- Ne koristi Attention mehanizam, već konvolucije za obradu slike.
- Za obuku je korišćen ConvNeXt Tiny - model od 28M parametara

Vision Transformer



- Zasnovana na Attention arhitekturi [3].
- Ima samo enkoder. Dekoder je nepotreban jer se ne generiše sekvenca.
- Slika se predstavi, uz pomoć projektora koji se uči, kao matrica, gde je svaka vrsta patch. Doda se još i kolona za klasu, kao i za poziciju.
- Dalje se prosleđuje Multihead Self Attention-u i Feed Forward Network-u.
- Za obuku je korišćen ViT Small od 21.7M parametara.

Swin transformer



- Zasnovana na Attention arhitekturi, ali sa hijerarhijskom komponentom.
- Slika se deli na male patch-eve (4×4), koji se u kasnijim slojevima postepeno spajaju.
- Time se dobija hijerarhijski efekat kao kod konvolutivnih mreža.
- Self-attention se ne računa globalno kao kod ViT-a, već lokalno unutar fiksnih prozora.
- Između uzastopnih blokova prozori se pomeraju, čime se ostvaruje komunikacija između susednih prozora. Korišćen je Swin Tiny od 27.7M parametara.

Trening skup

- Skup podataka je tiny-imagenet-200. Ima 200 klase. Svaka slika je 64x64.
- Trening skup ima 500 slika po klasi; validacioni skup 50 slika po klasi.
- Test skup nema pridružene klase, pa smo napravili test skup tako što smo nasumice iz svake klase iz trening skupa izabrali 25 slika.
- Tih 25 slika smo izbacili iz test skupa i stavili ih u test holdout skup, sa pridruženim klasama.
- Dakle na kraju 95000 slika u test skupu, odnosno 10000 slika u validacionom skupu, ravnomerno raspoređenih.
- 5000 slika u test holdout skupu, 25 po klasi.

Obučavanje modela 1

- Obučavanje modela smo vršili u tri iteracije.
- Prva iteracija je bila na našim računarima.
- Pokazalo se kao spor i praktično neupotrebljiv pristup.
- Obučavanje je išlo sporo. Da bi se prošlo kroz ceo trening skup, bilo je neophodno dan ili dva non-stop obučavanja.
- Pokušali smo da smanjimo skup na 5.000 slika, ali rezultati su, naravno, bili loši. Svaki od tri modela je imao ne više od 7–8% preciznosti na validacionom skupu posle 100 epoha.

Obučavanje modela 2

- S obzirom na to da su nam trebali računarski resursi, odlučili smo da iznajmimo A100 od 40 GB memorije na Google Colab-u.
- Na A100 smo imali dve iteracije.
- Druga iteracija je bila sa osnovnim podešavanjima, bez bilo kakvih regularizacija.
- U toj iteraciji postigli smo: Swin 39% validation accuracy; ConvNeXt 39% validation accuracy; ViT 32% validation accuracy.
- Da bismo poboljšali rezultate, odlučili smo da iskoristimo regularizacije. Te regularizacije i njihovi parametri najvećim delom su zasnovani na radovima [5] i [6].

Rezultati

- Sa regularizacijama trenirali smo modele 100 epoha ili 3 sata. Nijedan model se nije trenirao duže od 3 sata.
- Rezultati na test skupu su sledeći:

Model	Top-1 Acc (%)	Loss	Macro Prec (%)	Macro Rec (%)	Macro F1 (%)	Throughput (img/s)
ConvNeXt	49.08	2.2695	48.78	49.08	47.86	269.73
ViT	48.78	2.2850	47.75	48.78	47.44	361.70
Swin	56.70	1.8668	56.68	56.70	55.89	257.24

Zaključci

- Swin je najbolji model
 - Jasno se vidi po svim metrikama, osim po throughput-u, da se Swin arhitektura najbolje pokazala.
- - Regularizacija je dosta poboljšala modele
 - S obzirom na to da su modeli imali accuracy ne veći od 40% bez regularizacije, a sa njom oko 50%, za Swin arhitekturu čak i preko, jasno je da je ona ključna za dobre performanse.
- - ConvNeXt i ViT su praktično podjednako (ne)kvalitetni
 - Jedinu prednost ima ViT, u throughput metrici; po svim ostalim metrikama su isti.
- - **Potrebno je više podataka i veći modeli za korisno poredjenje**
 - S obzirom na to da su se koristili parametri i regularizacije koji su se pokazali kao dobri u različitim radovima, i da se posle 100 epoha obučavanja preciznost na validacionom skupu praktično nije menjala, možemo doći do zaključka da je lek više podataka. Kao i to da se koriste modeli sa većim brojem parametara.

Literatura

- [1] - Residual Attention Networks for Image Classification - Thaminda Edirisooriya
- [2] - A ConvNet for the 2020s - Liu et al.
- [3] - An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale - Dosovitskiy et al.
- [4] - Swin Transformer: Hierarchical Vision Transformer using Shifted Windows - Liu et al.
- [5] - Training data-efficient image transformers & distillation through attention - Touvron et al.
- [6] - Vision Transformers in 2022: An Update on Tiny Imagenet - Ethan M. Huynh